

Analyse de pression d'accès aux espaces d'un territoire pauvre en données, l'indice de pression d'accès (IPA)

Analyse de pression d'accès aux espaces d'un territoire pauvres en données, l'indice de pression d'accès (IPA)	1
I/ Cadre théorique des modèles d'accès, la 2SFCA	2
II/ Les spécificités de l'IPA	2
II.A. Une approche par bassin de proximité	3
II.B. Une focale sur la proximité quotidienne	3
II.C. L'indice comme outil opérationnel d'aide à la décision	3
III/ Méthodologie de calcul de l'Indice de Pression d'Accès (IPA)	4
III.A. La préparation des données et le maillage spatial	4
III.B. La modélisation des flux par le réseau	4
III.C. Calcul de l'indice de pression	5
III.D. Traitements statistiques et normalisation	5
IV/ Analyse et interprétation de l'Indice de Pression	5
V/ Limites et perspectives de l'Indice de Pression d'Accès (IPA)	6
V.A. Le postulat de l'équipement le plus proche	6
V.B. L'approximation de la capacité d'accueil	7
V.C. L'absence de critères qualitatifs	7
V.D. La dépendance à la qualité et l'exhaustivité des données sources	7
VI/ Perspectives d'évolution : Synergies et Co-localisation	8
VI.A. Vers l'intégration du chaînage des déplacements	8
VII/ Étude de cas, l'accès aux universités avignonnaises par les jeunes Avignonnais	9
VIII/ Conclusion	13
IX/ Bibliographie	13
X/ Annexes	14
Annexe 1 : Code R	14
Annexe 2 : Q-Q plot Log	19
Annexe 3 : Histogramme résidus	20
Annexe 4 : Homoscédasticité	21

I/ Cadre théorique des modèles d'accès, la 2SFCA

Comme le démontrent les travaux de l'OCDE (Di Ciommo, 2018) et les standards actuels de la géographie de la santé (Luo & Wang, 2003), mesurer la tension par le croisement de l'éloignement et de la saturation est la méthode la plus robuste pour identifier les zones de fracture territoriale.

L'indice de pression d'accès (IPA) développé ici s'inscrit dans le champ de la géographie quantitative et de l'économie urbaine. Sur le plan théorique, la formule retenue appartient à la famille des modèles d'interaction spatiale sous contrainte de capacité. Elle réalise une synthèse entre deux courants majeurs de la planification territoriale : les modèles gravitaires, qui mesurent la friction de l'éloignement, et les modèles de congestion, qui évaluent la dégradation du service par la saturation.

La méthodologie de l'IPA s'inscrit dans la lignée directe de la méthode 2SFCA (Two-Step Floating Catchment Area), formalisée par Luo et Wang (2003). Devenue la référence internationale pour l'analyse des déserts de services, cette approche consiste à évaluer l'offre disponible en fonction de la population desservie au sein de zones de chalandise mobiles.

II/ Les spécificités de l'IPA

En s'appuyant sur les travaux de Luo et Qi (2009), ce modèle intègre une friction de distance continue pour refléter la réalité des parcours. L'IPA constitue ainsi une « inversion » du 2SFCA : là où ce dernier mesure une disponibilité positive, l'IPA isole la tension générée par la compétition pour l'accès aux ressources. Alors que la méthode 2SFCA agrège les opportunités de service pour mesurer un confort d'accès, l'IPA isole la charge exercée par la population sur l'infrastructure la plus proche, multipliée par l'effort de déplacement, afin d'identifier les points de rupture du réseau. Il est important de noter que la création de cet indice s'est articulée autour de la volonté de créer un calcul opérable dans un contexte où les données en entrée sont dégradées ou peu nombreuses.

II.A. Une approche par bassin de proximité

Une différence majeure vis à vis du 2SFCA est que nous avons opté pour une approche par "bassin de proximité" afin de correspondre à une qualité de données d'entrée dégradées.

Le choix d'assigner chaque carreau de population exclusivement à l'infrastructure la plus proche (distance réseau minimale) constitue un parti pris méthodologique délibéré, qui

s'écarte de la logique de « zone de chalandise flottante » (2SFCA) pour privilégier une analyse de la dépendance territoriale.

En effet, le modèle 2SFCA tend à lisser l'accessibilité en considérant que l'utilisateur peut arbitrer entre plusieurs équipements dans un rayon donné tandis que notre modèle d'IPA isole la pression sur le pôle de référence. En limitant l'assignation au plus proche, l'indice met en évidence les zones de rupture.

Le choix d'une infrastructure par les usagers est multifactoriel, ici nous opérons une simplification de ce choix. La modélisation de celui-ci demandera des données d'acquisition complexes. De plus, cette démarche nécessite d'aller contre cette volonté de proposer un indice opérable avec des données dégradées.

II.B. Une focale sur la proximité quotidienne

Pour de nombreuses infrastructures de proximité, l'usage est dicté par une logique d'hyper-proximité. Comme le démontrent Weng et al. (2019) dans leurs travaux sur les voisinages marchables, le franchissement d'un seuil de distance agit comme un "frein définitif" à la fréquentation des équipements. En s'appuyant sur ce cadre théorique de la « Ville du quart d'heure » (Moreno, 2021), l'assignation au plus proche permet de diagnostiquer la résilience du maillage de base sans lisser les disparités locales par un accès théorique à des pôles distants.

II.C. L'indice comme outil opérationnel d'aide à la décision

L'IPA est une tentative de modélisation mathématique du concept de « double peine territoriale ». Ce cadre d'analyse traduit le vécu des populations périphériques ou vulnérables qui subissent un cumul de désavantages : d'une part, un coût de transport élevé lié à l'éloignement physique, et d'autre part, une qualité de service dégradée par des infrastructures saturées ou sous-dimensionnées.

D'un point de vue stratégique, cette méthode permet de sectoriser le diagnostic. Chaque maille se voit attribuer un « niveau de pression » clair, facilitant l'identification des sites prioritaires pour une extension ou une rénovation. De plus, cet indice pondère le déficit d'offre par la longueur du trajet, ce qui permet de dépasser la simple cartographie des équipements pour révéler les ruptures territoriales. Ainsi l'indice permet d'identifier les lieux où l'investissement public serait le plus urgent pour rétablir l'équité républicaine sur le territoire.

Pour un décideur public, une carte montrant des dépendances directes est plus actionnable qu'une carte de probabilité, ou de « facilité » d'accès, car elle désigne précisément quel levier actionner pour soulager la tension d'un secteur donné.

III/ Méthodologie de calcul de l'Indice de Pression d'Accès (IPA)

Cet indice est multidimensionnel. Il est à la fois géographique (distance à parcourir) et sociale (concurrence entre les ménages pour l'accès à un même équipement). De ce fait la méthodologie s'articule autour de quatre étapes clés :

III.A. La préparation des données et le maillage spatial

L'analyse repose sur le carroyage de 200 mètres de côté de l'INSEE (philosophie). Pour chaque carreau, deux variables fondamentales ont été extraites : le nombre de ménages résidents (Men) et le nombre d'infrastructures par type présentes dans le carreau (nb_infra).

III.B. La modélisation des flux par le réseau

Nous avons choisi d'utiliser la distance par le réseau de voirie (network_cost) vers l'infrastructure la plus proche, que nous calculons grâce à l'extension QNEAT3 de QGIS. Cette méthode offre une mesure de la "friction de la distance", reflétant les parcours effectifs des usagers, tout en étant affranchie du choix du mode de transport. Chaque carreau de population a été assigné exclusivement à l'équipement le plus proche afin de définir des bassins de fréquentation (influence) théoriques.

III.C. Calcul de l'indice de pression

Pour chaque trajet, un indice de pression brut est calculé selon une formule intégrant la concurrence entre les quartiers tel que :

$$IPA = (M * DR) * \left(\frac{NB_M}{NB_{INF}} \right)$$

avec M la population étudiée dans la maille (ici le nombre de ménage), DR la distance par le réseau, NB_M le nombre de ménages ayant pour destination la même infrastructure et NB_{INF} le nombre d'infrastructure du même type dans la maille de destination.

Cette équation permet de pondérer l'effort individuel (distance) par un coefficient de saturation à destination. Le ratio « nombre de ménages allant à la même infrastructure / nombre d'infrastructure du même type à proximité » représente la charge d'usagers par équipement disponible. L'indice identifie ainsi une "double peine" : une population nombreuse, éloignée d'un site déjà saturé par la demande d'autres quartiers. La saturation agissant ici comme un proxy de la dégradation potentielle du service.

III.D. Traitements statistiques et normalisation

Afin de stabiliser la distribution des données, une transformation logarithmique a été appliquée. Enfin, les résultats ont été ramenés sur une échelle de 0 à 100 via une normalisation Min-Max. Un score de 100 représente le niveau de pression le plus critique, où le cumul de l'éloignement et de la saturation de l'offre atteint son maximum. Ce mode de représentation a été choisi pour simplifier la lecture et l'interprétation.

De plus, cet indice ayant pour destination la cartographie et ayant pour objectif d'aider à une lecture synoptique des différences de niveau d'accessibilité des infrastructures sur un territoire. Les équipements mesurés reposent sur des logiques d'usage distinctes, de ce fait l'utilisation d'une base de normalisation commune (0 à 100) permet d'effacer les disparités d'unités de mesure initiales.

Le choix de la discrétisation pour la représentation cartographique s'est porté sur la méthode des seuils naturels (Jenks). Cette approche permet de regrouper les mailles ayant des scores d'IPA similaires en minimisant la variance intra-classe et en maximisant la variance inter-classe. Dans le cadre d'un outil d'aide à la décision, ce choix est stratégique : il ne cherche pas à lisser l'information mais à souligner les ruptures territoriales réelles. Les seuils ainsi définis permettent d'isoler visuellement les zones de "confort" des zones de "tension critique" (proches de 100), rendant le diagnostic immédiatement actionnable pour identifier les sites prioritaires.

IV/ Analyse et interprétation de l'Indice de Pression

L'indice développé constitue une mesure synthétique de la "pression de service" sur le territoire. Plutôt qu'une évaluation isolée du trajet, il traduit la viabilité du système d'offre face à la masse des usagers. En intégrant la charge totale à destination, il permet d'observer deux types de situation : les espaces délaissés par manque d'équipements proches, et les localisations dont l'équipement de référence est "victime de son succès" car partagé par un trop grand bassin de population.

La structure de cet indice repose sur une synergie de facteurs aggravants. Un score élevé peut révéler une situation de saturation systémique : les habitants doivent fournir un effort de déplacement important pour atteindre une infrastructure dont la capacité d'accueil est déjà fortement sollicitée par la collectivité. L'indice ne mesure donc pas seulement l'isolement, mais la concurrence entre les usagers dans des quartiers où l'offre est sous-dimensionnée par rapport aux besoins réels.

L'interprétation de la valeur sur l'échelle de 0 à 100 permet d'orienter les politiques publiques. Les scores les plus hauts (proches de 100) signalent les points où la demande excède davantage que sur le reste du territoire les capacités locales. À l'inverse, les scores les plus bas caractérisent des zones de "confort territorial" où la faible pression démographique et/ou l'abondance d'équipements garantissent un accès fluide. Entre ces pôles, les zones de vigilance (scores intermédiaires) désignent les quartiers où l'équilibre est précaire et où tout nouveau projet immobilier devra impérativement s'accompagner d'un renforcement des infrastructures de proximité.

V/ Limites et perspectives de l'Indice de Pression d'Accès (IPA)

Malgré cela, l'IPA repose sur une modélisation simplifiée de la réalité urbaine. Il convient de souligner plusieurs limites inhérentes à cette approche.

V.A. Le postulat de l'équipement le plus proche

L'IPA repose sur l'hypothèse que l'usager se dirige systématiquement vers l'infrastructure la plus proche de son domicile. Or, les comportements de mobilité réelle sont beaucoup plus complexes.

Un habitant peut avoir un gymnase au pied de son immeuble, mais se déplacer parce que c'est là que se trouve le seul club d'escrime ou de gymnastique rythmique dans les environs. L'indice traite par exemple le "sport" comme une catégorie monolithique, sans distinguer les disciplines. Cette simplification se fait peu importe la donnée en entrée, ainsi si la focale n'est pas assez précise les résultats peuvent contenir plus ou moins de biais.

De plus, le choix d'un équipement dépend souvent de la qualité perçue, de l'état d'entretien, du coût de l'adhésion ou même de l'habitude. Dans le même temps, certains quartiers peuvent être évités pour des raisons de sentiment d'insécurité ou de barrières symboliques. À l'inverse, un usager peut choisir un équipement proche de son lieu de travail ou de l'école de ses enfants plutôt que de son domicile.

V.B. L'approximation de la capacité d'accueil

Bien que notre formule intègre le nombre d'infrastructures, elle ne reflète pas la capacité d'accueil réelle.

Ainsi l'indice traite de la même manière un complexe sportif multi-sports capable d'accueillir des centaines de personnes et un simple plateau d'EPS en accès libre.

La capacité d'un site dépend aussi de ses créneaux d'ouverture et de sa gestion (usage scolaire vs usage club). Un équipement "proche" peut être saturé par des réservations scolaires, le rendant inaccessible au grand public en journée.

V.C. L'absence de critères qualitatifs

L'IPA est un indicateur quantitatif. Il ne tient pas compte de l'obsolescence éventuelle du patrimoine sportif. Un score de faible pression sur la carte pourrait cacher une réalité de terrain où l'équipement, bien que proche et peu fréquenté, est trop dégradé pour être utilisé correctement.

V.D. La dépendance à la qualité et l'exhaustivité des données sources

Au-delà des choix de modélisation, la précision de l'IPA est intrinsèquement liée à la fiabilité des bases de données utilisées. L'indice a été conçu pour fonctionner avec des bases de données peu enrichies afin d'être adaptable, mais la qualité de celle-ci reste indispensable. Ainsi plusieurs biais liés aux données fournies doivent être pris en compte dans l'interprétation des résultats.

Les bases de données sur les infrastructures ne peuvent pas toujours être exhaustives. L'absence de certains équipements dans les fichiers fournis peut fausser localement l'indice. En ignorant une offre existante mais non répertoriée, le modèle surestime mécaniquement la pression sur les équipements officiels voisins.

Une limite majeure réside dans le déficit d'informations qualitatives au sein du calcul. L'absence de prise en compte de la capacité d'accueil réelle et des équipements spécifiques, contraint à traiter chaque infrastructure comme une unité équivalente. Or, l'impact d'un complexe multisports sur un quartier n'est pas comparable à celui d'un plateau d'EPS en accès libre. Le modèle les comptabilise de manière identique pour que l'indice soit utilisable même dans le cas d'une base de données sans renseignements plus fins.

Le décalage temporel entre la collecte des données (notamment les données démographiques de l'INSEE) et la réalité actuelle du terrain peut induire des biais. De même, des erreurs dans les équipements listés mais actuellement fermés (pour travaux ou fermeture définitive) peuvent créer des zones de faible pression artificielles sur la carte qui ne correspondent plus à la réalité vécue par les résidents.

Le cadre d'usage de cet indice est donc à réserver aux analyses avec un nombre réduit de donnée, mais de bonne qualité pour éviter les biais. De plus il est nécessaire de placer la focale sur des lieux de fréquentation (destination) comparable entre eux en terme de taille mais aussi de spécificité.

VI/ Perspectives d'évolution : Synergies et Co-localisation

Pour affiner la pertinence de l'IPA dans une optique d'aménagement durable, il convient d'envisager l'intégration de la proximité inter-infrastructurelle. La littérature scientifique démontre que l'utilité d'un équipement ne dépend pas uniquement de sa position intrinsèque, mais de son insertion dans un écosystème de services, illustrant ainsi les économies d'agglomération appliquées aux déplacements des individus.

VI.A. Vers l'intégration du chaînage des déplacements

Le concept de chaînage de déplacements, théorisé par Adler et Ben-Akiva (1979) puis approfondi par Hanson (1980) et Kitamura (1988) dans le cadre de l'approche par l'activité, souligne que l'utilisateur ne perçoit pas ses trajets de manière isolée mais cherche à optimiser des séquences de déplacements complexes. Comme le démontre Cervero (1988), l'insertion d'un équipement dans un tissu urbain mixte réduit considérablement le coût marginal de l'accès en favorisant ces boucles multi-objectifs, permettant ainsi de transformer l'infrastructure de service en un maillon intégré d'un écosystème de proximité.

À l'inverse, un équipement isolé génère une tension maximale en imposant un déplacement dédié. L'évolution de l'IPA pourrait ainsi intégrer un coefficient de synergie au dénominateur de la formule. Un tel ajustement permettrait d'aligner l'outil sur les paradigmes de la « ville du quart d'heure » et de la « ville compacte », mais réduirait son opérabilité.

Pour les services de la Ville, cette évolution permettrait de ne plus arbitrer les projets uniquement sur la base du foncier disponible ou du coût de construction. Elle valoriserait les localisations favorisant la mixité fonctionnelle, réduisant ainsi mécaniquement l'empreinte carbone globale des déplacements générés et garantissant une meilleure rentabilité fonctionnelle des investissements.

VII/ Étude de cas, l'accès aux universités avignonnaises par les jeunes Avignonnais

Afin d'étayer l'utilité de cet indice nous allons l'utiliser dans le cadre de l'analyse de la pression d'accès des jeunes Avignonnais aux sites universitaires de la commune.

Pour ce faire nous suivons les étapes explicitées dans la partie 3. Vous retrouverez les détails des calculs de l'indice et des analyses des résultats dans les annexes.

Suite aux calculs nous aboutissons aux résultats suivants.




Figure 1 : Localisation de l'IPA des jeunes Avignonnais aux universités Avignonnaises

Nous pouvons observer sur cette carte ci-contre que les indices les plus élevés se trouvent dans le centre historique, mais aussi et surtout dans la première couronne périphérique. Elles sont à Avignon parmi les zones les plus peuplées notamment par des individus plus jeunes, ce qui explique cette pression plus haute malgré la faible distance. Les espaces de proches périphéries permettent une proximité aux divers infrastructure de la ville tout en contenant le coût du foncier, contrairement au cœur historique d'Avignon.

Cependant le manque d'accès aux infrastructures est dans la littérature corrélé à des espaces où la pauvreté est accrue. Cette injustice spatiale a notamment été théorisée par Kain J. F. en 1968 dans l'article "Housing Segregation, Negro Employment, and Metropolitan Decentralization". Plus récemment c'est Lucas K. en 2012, qui dans son article "Transport and social exclusion: Where are we now?" démontre l'existence d'un cercle vicieux où le manque d'investissements publics dans les quartiers pauvres limite la mobilité, ce qui limite l'accès à l'éducation et à la santé, renforçant ainsi la pauvreté.

En corrélant notre indice à un indice de pauvreté dans une droite de régression linéaire nous devrions, si la littérature et notre indice sont justes, trouver une corrélation positive. En théorie plus la difficulté d'accès augmente plus les ménages sont défavorisés.

Dans un premier temps nous avons, sans vérifier les conditions d'application, calculé le modèle, où X (variable explicative) est le nombre de ménage dit « pauvre », et Y (notre variable à expliquer) est notre indice sur 100. Nous obtenons le résultat ci-dessous.

Relation Brute : Ménages pauvres et IPA (0-100)

$R^2 = 0.679$ (Modèle linéaire simple)




Figure 2 : Relation Ménages pauvre et score IPA sur 100, sans modification

Avec un R^2 de 0.679, les résultats sont très satisfaisants. Cependant au regard de la non-normalité des résidus (Shapiro-Wilk) et de la présence de valeurs aberrantes, nous ne pouvons pas valider la robustesse de ce modèle. De ce fait nous allons utiliser l'indice brut, transformé par un logarithme 10 comme variable explicative.

Afin de garantir la robustesse du modèle de régression log-linéaire, une analyse des valeurs aberrantes (outliers) a été réalisée. La détection s'est fondée sur l'analyse des résidus studentisés (R-student). Compte tenu de la taille de l'échantillon nous avons appliqué la correction de Bonferroni au seuil de significativité ($\alpha = 0.05$) afin d'éviter la détection de faux positifs liés aux tests multiples.

Le test de Bonferroni est une méthode conservatrice. Il ne supprime pas une proportion fixe de données, mais uniquement les observations dont la probabilité d'appartenir à la distribution normale est inférieure à 0.05 divisé par la taille de l'échantillon (après ajustement du seuil par la taille de l'échantillon).

Seules les observations présentant un résidu studentisé extrême, associé à une p-value ajustée de Bonferroni inférieure à 0,05, ont été exclues du modèle final. Cette procédure a permis d'écarter 10 observations correspondant à des anomalies statistiques ne reflétant pas la tendance générale du territoire.

Modèle Final : Le lien entre précarité et pression d'accès (Log)

$R^2 = 0.138$ | Outliers exclus : 10




Figure 3 : Relation ménages pauvre et score IPA log, avec traitement des données

Le modèle final affiche une p-value extrêmement significative $< 2.2e-16$ et un coefficient de détermination (R^2) de 0.138. Si la pauvreté ne suffit pas à prédire l'intégralité du score d'IPA (l'erreur moyenne restant de 38.8 points), elle exerce une influence systématique : l'augmentation de la précarité est statistiquement associée à une hausse de la pression d'accès. Ce résultat valide la pertinence de l'IPA comme descripteur des inégalités socio-spatiales. Cependant la pauvreté est un facteur aggravant significatif mais qu'elle n'est pas le seul moteur de la pression d'accès.

VIII/ Conclusion

L'Indice de Pression d'Accès (IPA) propose une alternative hybride aux mesures d'accessibilité classiques. En intégrant la charge systémique (concurrence pour la ressource) à la friction de la distance, il permet une lecture plus fine des déséquilibres territoriaux.

Si l'interopérabilité de l'indice constitue sa force majeure (grâce à l'utilisation de données de carroyage standardisées), elle impose également des limites. L'absence de variables qualitatives sur l'état des infrastructures, la qualité des données en entrée, l et l'utilisation d'une maille spatiale fixe (200m) appellent à une certaine prudence dans l'interprétation. En conclusion, l'IPA se positionne moins comme un outil prédictif absolu que comme un instrument de diagnostic exploratoire, capable de désigner les zones de rupture où le

système de services publics est mis sous tension par la structure géographique de la démographie.

IX/ Bibliographie

Luo, W., & Wang, F. (2003). *Measures of spatial accessibility to health care in a GIS environment: synthesis and a case study in the Chicago region. Environment and Planning B.*

Kain, J. F. (1968). *Housing Segregation, Negro Employment, and Metropolitan Decentralization. The Quarterly Journal of Economics.*

Vickrey, W. S. (1969). *Congestion Theory and Transport Investment. American Economic Review.*

Barlet, M., Coldefy, M., et al. (2012). *L'accessibilité potentielle localisée (APL) : une nouvelle mesure de l'accessibilité aux soins. DREES (Ministère de la Santé).*

Soukhov, A., Páez, A., et al. (2023). *Introducing spatial availability, a measure of accessibility taking into account the competition for opportunities. PLOS ONE.*

Cervero, R. (1996). *Mixed Land-Uses and Commuting: Evidence from the American Housing Survey. Transportation Research Part A.*

Weng, M., et al. (2019). *The 15-minute walkable neighborhoods: Measurement, social inequalities and implications for self-sufficient communities. Urban Studies.*

X/ Annexes

Annexe 1 : Code R

```
library(dplyr)
library(readr)
library(car)
library(ggplot2)
library(ggpubr)
library(tidyverse)

# =====
# 1. PRÉPARATION DES DONNÉES
# =====

# Chargement
Matrice_distance = read.csv("C:/Users/thema/Desktop/Master GEOTER/IPA/Traitements/Matrice_distance.csv", sep = ",", dec = ".", stringsAsFactors = FALSE) 1
Carreaux_INSEE = read.csv("C:/Users/thema/Desktop/Master GEOTER/IPA/Traitements/Carreaux_INSEE.csv") 1

# Destination la plus courte
Distance_la_plus_courte_par_origine = Matrice_distance %>%
  group_by(origin_id) %>%
  slice_min(network_cost, n = 1, with_ties = FALSE) %>%
  select(origin_id, destination_id, network_cost)
```

```

# Calcul charge
charge_destination = Distance_la_plus_courte_par_origine %>%
  left_join(Carreaux_INSEE %>% select(fid, Ind_18_24), by = c("origin_id" = "fid")) %>%
  group_by(destination_id) %>%
  summarise(total_pop_dest = sum(as.numeric(Ind_18_24), na.rm = TRUE)) %>%
  ungroup()

# Tableau final
resultat = Distance_la_plus_courte_par_origine %>%
  left_join(Carreaux_INSEE %>% select(fid, Pop_orig = Ind_18_24, Men_pauv), by = c("origin_id" = "fid")) %>%
  left_join(Carreaux_INSEE %>% select(Idcar_200m, Nb_dest), by = c("destination_id" = "Idcar_200m")) %>%
  left_join(charge_destination, by = "destination_id") %>%
  mutate(
    network_cost = as.numeric(network_cost),
    Pop_orig = as.numeric(Pop_orig),
    total_pop_dest = as.numeric(total_pop_dest),
    Nb_dest = as.numeric(Nb_dest),
    Men_pauv = as.numeric(Men_pauv)
  ) %>%
  filter(!is.na(network_cost)) %>%
  mutate(
    # Indice Brut calculé
    indice_brut_calcul = (Pop_orig * network_cost) * (total_pop_dest / Nb_dest)
  ) %>%
  ungroup() %>%
  mutate(
    # Variable Y1 : Log (Pour la rigueur statistique)
    log_indice_brut = log(indice_brut_calcul + 0.000001),

    # Variable Y2 : Sur 100 (Pour la lisibilité)
    indice_sur_100 = (indice_brut_calcul - min(indice_brut_calcul, na.rm = TRUE)) /
      (max(indice_brut_calcul, na.rm = TRUE) - min(indice_brut_calcul, na.rm = TRUE)) * 100
  )

write.csv2(resultat,
  "C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Traitements/resultat.csv",
  row.names = FALSE)

# =====
# ÉTAPE 1 : PREMIER APERÇU (NAÏF)
# Y = Indice 0-100 (IPA) | X = Ménages pauvres
# =====

# Modèle "Brut de décoffrage"
modele_brut = lm(indice_sur_100 ~ Men_pauv, data = resultat)

cat("\n--- Résumé Modèle 1 (Brut sur 100) ---\n")
print(summary(modele_brut))

# Graphique 1
Plot_Brut = ggplot(resultat, aes(x = Men_pauv, y = indice_sur_100)) +
  geom_point(alpha = 0.3, color = "grey50") +
  geom_smooth(method = "lm", color = "red", se = TRUE) +
  labs(
    title = "Diagnostic Brut : La précarité augmente-t-elle la Pression ?",
    subtitle = paste("R² =", round(summary(modele_brut)$r.squared, 3),
      "(Modèle linéaire simple sur indice 0-100)",
    x = "Nombre de ménages pauvres (Explicatif)",
    y = "Indice de Pression sur 100 (À expliquer)"
  )

```

```

) +
theme_minimal()

print(Plot_Brut)
ggsave("C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Graphique/1_Modele_Brut_Indice100.png",
       plot = Plot_Brut, width = 10, height = 7, bg = "white")

# =====
# ÉTAPE 2 : TRANSITION VERS LE LOG
# Y = Log(IPA) | X = Ménages pauvres
# =====

# Calcul du modèle Log
modele_log = lm(log_indice_brut ~ Men_pauv, data = resultat)

# Test de Bonferroni (Détection des anomalies statistiques)
outlier_results = outlierTest(modele_log)
print(outlier_results)

# Q-Q Plot (Vérification Normalité)
resultat$residus_log = residuals(modele_log)
qq_plot = ggqqplot(resultat, "residus_log") + labs(title = "Q-Q Plot (Modèle Log)")
ggsave("C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Graphique/3_QQ_Plot_Log.png",
       plot = qq_plot, width = 8, height = 6, bg = "white")

# =====
# ÉTAPE 3 : NETTOYAGE ET MODÈLE FINAL
# On enlève les outliers pour voir la tendance de fond
# =====

lignes_aberrantes = as.numeric(names(outlier_results$rstudent))

if (length(lignes_aberrantes) > 0) {

  message(paste("Nombre d'outliers détectés et supprimés :", length(lignes_aberrantes)))

  # A. Données Propres
  resultat_clean = resultat[-lignes_aberrantes, ]

  # B. Modèle Final
  modele_final = lm(log_indice_brut ~ Men_pauv, data = resultat_clean)

  # C. Comparaison des R²
  cat("\n--- COMPARAISON R² ---\n")
  cat("Brut (0-100) : ", round(summary(modele_brut)$r.squared, 4), "\n")
  cat("Log (Sale) : ", round(summary(modele_log)$r.squared, 4), "\n")
  cat("Log (Clean) : ", round(summary(modele_final)$r.squared, 4), "\n")
  cat("-----\n")

  # D. Graphique Final
  Plot_Final = ggplot(resultat_clean, aes(x = Men_pauv, y = log_indice_brut)) +
    geom_point(alpha = 0.3, color = "#2c7fb8") +
    geom_smooth(method = "lm", color = "#08306b", se = TRUE) +
    labs(
      title = "Modèle Final : Le lien entre précarité et pression d'accès (Log)",

```

```

    subtitle = paste("R² =", round(summary(modele_final)$r.squared, 3),
                    "| Outliers exclus :", length(lignes_aberrantes)),
    x = "Nombre de ménages pauvres",
    y = "Log(Indice de Pression d'Accès)"
  ) +
  theme_minimal()

print(Plot_Final)
ggsave("C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Graphique/2_Modele_Final_Log_Clean.png",
       plot = Plot_Final, width = 10, height = 7, bg = "white")

# E. Export des outliers pour Carto
donnees_exclues = resultat[lignes_aberrantes, ]
donnees_exclues$Type = "Outlier Bonferroni"
write.csv2(donnees_exclues,
           "C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Traitements/Outliers_Exclus.csv",
           row.names = FALSE)
write.csv2(resultat_clean,
           "C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Traitements/resultat_clean.csv",
           row.names = FALSE)

# Calcul des résidus finaux pour la carte choroplèthe
resultat_clean$residus_finaux = residuals(modele_final)

} else {
  message("Pas d'outliers détectés.")
  resultat_clean = resultat
  modele_final = modele_log
  resultat_clean$residus_finaux = residuals(modele_final)
}

# =====
# ÉTAPE 4 : DIAGNOSTICS VISUELS
# =====

# Histogramme des résidus
Hist_residus = gghistogram(resultat_clean, x = "residus_finaux",
                           fill = "steelblue", bins = 30, add = "mean", rug = TRUE) +
  labs(title = "Distribution des résidus (Modèle final)",
       x = "Résidus", y = "Fréquence")

ggsave("C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Graphique/4_Histogramme_Residus.png",
       plot = Hist_residus, width = 8, height = 6, bg = "white")

# Homoscédasticité
png("C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Graphique/5_Homoscedasticite.png",
    width = 2400, height = 1800, res = 300)
plot(modele_final, which = 3, main = "Homoscédasticité")
dev.off()

# =====
# ÉTAPE 5 : CALCUL PRÉCISION (RAMENÉE À L'ÉCHELLE 0-100)
# Pour pouvoir interpréter concrètement l'erreur
# =====

```

1. Prédiction en Log

```
pred_log = predict(modele_final, newdata = resultat_clean)
```

2. Conversion : Log -> Valeur Brute (Exp)

```
pred_brut = exp(pred_log)
```

3. Normalisation : Valeur Brute -> Echelle 0-100 (Avec Min/Max globaux)

```
min_ref = min(resultat$indice_brut_calcul, na.rm = TRUE)
```

```
max_ref = max(resultat$indice_brut_calcul, na.rm = TRUE)
```

```
pred_100 = (pred_brut - min_ref) / (max_ref - min_ref) * 100
```

4. Comparaison avec la réalité (déjà sur 100)

```
real_100 = resultat_clean$indice_sur_100
```

5. Métriques

```
mae_100 = mean(abs(pred_100 - real_100))
```

```
rmse_100 = sqrt(mean((pred_100 - real_100)^2))
```


6. Export Tableau Final pour CARTE

```
write.csv2(resultat_clean,
```


```
  "C:/Users/thema/Desktop/Master 1 GEOTER/IPA/Traitements/Resultats_Pression_Carte.csv",
```

```
  row.names = FALSE)
```

Annexe 2 : Q-Q plot Log



Annexe 3 : Histogramme résidus



Annexe 4 : Homoscédasticité

Homoscédasticité

Scale-Location

